

EDA con Python



Manejo de datos nulos

En este análisis se han manejado los datos antes de tratarlos para su estudio, ya que la plantilla inicial no era válida para un EDA adecuado. Primero lo que se ha hecho ha sido el manejo de valores nulos, poniendo distintas condiciones:

- Eliminar aquellos datos nulos donde dicha **columna no supere el 2%** de los mismos
- Tratar los datos nulos de la columna '**default**' como valores verdaderos, ya que el resto de datos son no nulos de valor cero, así supuse que el resto debía ser verdadero.
- Tratar los datos nulos de la columna '**euribor3m**' sustituyendo los valores nulos por el valor inmediatamente superior que tengan, ya que los valores no nulos tienen este orden de mayor a menor, los nulos también.
- Poner las siguientes condiciones a los valores nulos de la columna '**age**':
 - Edad entre 22 a 30 años: estado 'SINGLE'
 - Edad entre 17 a 22 años: educación distinta a 'university' ni profesional y estado 'SINGLE'
 - Edad entre 30 a 98 años:
 - Columna marital 'SINGLE': 10% de probabilidad
 - Columna marital 'MARRIED': 90% de probabilidad

Esto se ha hecho solo en el archivo csv, ya que en el Excel no había ningún dato nulo.

Manejo de datos corruptos

Reemplazar aquella columna que tenga de tipo de variable no numérica a numérica.

Creación del nuevo 'Data Frame'

Se ha creado un nuevo archivo csv para su posterior estudio



Expresión de los datos

Se ha desglosado la información de los archivos en forma de texto con las cantidades, estadísticos, porcentajes, máximos, mínimos...

Se han creado una miríada de gráficos expresando la información de las tablas en distintos formatos, tanto en las variables cuantitativas como las cualitativas.

Análisis Exploratorio de Datos (EDA)

- **Distribución por edad:** El gráfico de distribución de frecuencia de la variable "age" muestra una distribución con una clara asimetría positiva, o sesgada hacia la derecha. La mayoría de los datos se concentran en el rango de 25 a 60 años, con un pico de frecuencia notable entre los 30 y los 40 años, lo que sugiere que este es el grupo de edad más representado en el conjunto de datos. A partir de los 40 años, la frecuencia disminuye progresivamente, aunque se observa un segundo pico menos pronunciado alrededor de los 42 años. Para edades mayores de 60 años, la distribución se aplan considerablemente, con una frecuencia baja y relativamente constante hasta los 100 años, indicando que hay una menor cantidad de individuos en estos grupos de edad más avanzados. Este análisis visual revela que la muestra está predominantemente compuesta por adultos jóvenes y de mediana edad.



Algunos de los estadísticos de esta columna son:

La media es de aproximadamente 41.09 años, mientras que la mediana (50%) es de 39.00 años. La diferencia entre la media y la mediana sugiere una distribución asimétrica positiva (sesgada a la derecha), lo que confirma lo que ya se observaba en el histograma. La media es superior a la mediana porque la cola de valores altos (edades mayores) arrastra el promedio hacia arriba.

La desviación estándar (std) es de 13.24 años. Este valor indica que las edades se desvían, en promedio, unos 13.24 años respecto a la media. Es una medida de la dispersión de los dato

El rango de edad completo va desde el mínimo (min) de 17 años hasta el máximo (max) de 98 años.


Los cuartiles nos dan una visión más granular de la distribución:

- El **25%** de los individuos tienen **32 años o menos**.
- El **50%** de los individuos tienen **39 años o menos** (la mediana).
- El **75%** de los individuos tienen **48 años o menos**.


Esto significa que el 50% central de los datos (entre el 25% y el 75%) se encuentran en el rango de 32 a 48 años, lo que confirma que la mayor concentración de la población se sitúa en un rango de edad relativamente joven y de mediana edad.

- **Distribución de interacciones** El gráfico de distribución de frecuencia de la variable "duration" muestra una asimetría extrema y positiva, con la inmensa mayoría de los datos concentrándose en el extremo inferior del eje horizontal. Esto indica que la mayoría de las interacciones con los clientes son muy cortas, con duraciones que se encuentran cerca de cero segundos. La distribución presenta una cola muy larga y dispersa que se extiende hacia la derecha, lo que revela la existencia de un pequeño número de interacciones con duraciones significativamente más altas. Estas interacciones de larga duración son atípicas en comparación con el grueso de los datos. En resumen, el análisis visual confirma que el conjunto de datos está dominado por un gran volumen de interacciones breves, mientras que las interacciones prolongadas son eventos raros y minoritarios.

Distribución de Frecuencia del duration



Estimación de Densidad del duration



Algunos de los estadísticos de esta columna son:

Analizando las estadísticas descriptivas de la variable "duration", podemos obtener información más precisa que complementa el análisis visual del histograma.

El conteo total es de 41,872 interacciones. La media de la duración es de 257.69 segundos, mientras que la mediana (50%) es de 179.00 segundos. La significativa diferencia entre la media y la mediana confirma la asimetría positiva de la distribución. La media es arrastrada hacia arriba por la presencia de unas pocas interacciones de muy larga duración, mientras que la mediana, al ser resistente a los valores extremos, refleja de manera más precisa la duración típica de las interacciones.

La desviación estándar (std), que mide la dispersión de los datos, es de 258.90 segundos, un valor bastante alto y comparable al de la media. Esta gran desviación estándar subraya la amplia variabilidad en las duraciones y la presencia de valores muy alejados del promedio, tal como se observaba en el gráfico.

Las duraciones van desde un mínimo de 0.00 segundos (posibles errores de registro o interacciones no iniciadas) hasta un máximo de 4918.00 segundos, que equivale a más de 81 minutos.


Los cuartiles nos dan una visión más detallada de la distribución:

- El **25%** de las interacciones duran **102 segundos o menos**.
- El **50%** de las interacciones duran **179 segundos o menos**.
- El **75%** de las interacciones duran **319 segundos o menos**.


Esto nos indica que el 50% central de las interacciones se encuentran en el rango de 102 a 319 segundos. Estos datos confirman que la gran mayoría de las interacciones son relativamente cortas, mientras que las de más de 319 segundos (el 25% superior) son considerablemente más largas, con la cola de la distribución extendiéndose hasta casi los 5000 segundos.

- **Distribución del número de contratos:** El gráfico de la variable "campaign" muestra una distribución de frecuencia que está fuertemente sesgada a la derecha. Esto significa que la gran mayoría de las interacciones con los clientes se produjeron en un número muy bajo de contactos de campaña. La barra más alta en el gráfico corresponde a un valor de 1, indicando que la mayoría de los clientes solo fueron contactados una sola vez. La frecuencia disminuye drásticamente a medida que aumenta el número de contactos, lo que sugiere que muy pocos clientes fueron contactados múltiples veces. La distribución se extiende con una cola larga hacia la derecha, lo que demuestra que un número muy pequeño de clientes fueron contactados hasta 50 o más veces.

Distribución de Frecuencia del campaign



Estimación de Densidad del campaign



Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "campaign" confirman la fuerte asimetría positiva observada en el histograma.

El conteo de 41,872 interacciones se alinea con los datos anteriores. La media de 2.56 contactos es significativamente mayor que la mediana (50%) de 2.00, lo que nuevamente subraya que los valores extremos (un pequeño número de clientes contactados muchas veces) influyen fuertemente en el promedio.


El número de contactos por campaña oscila entre un mínimo de 1 y un máximo de 56. Los cuartiles muestran que:

- El **25%** de las personas fueron contactadas solo **una vez**.
- El **50%** (la mediana) fueron contactadas **dos veces o menos**.
- El **75%** fueron contactadas **tres veces o menos**.


Esto revela que el 50% central de los datos se encuentra en un rango muy estrecho, entre 1 y 3 contactos. La gran mayoría de los clientes (el 75%) solo fueron contactados hasta tres veces, lo que enfatiza que la estrategia de campaña se centra en un número bajo de interacciones por cliente.

Distribución del número de contactos con el cliente: El gráfico de distribución de frecuencia de la variable "previous" muestra un sesgo positivo extremadamente pronunciado. Esto indica que la inmensa mayoría de los clientes no fueron contactados previamente en campañas anteriores. La barra más alta, en el valor 0, tiene una frecuencia de más de 35,000, lo que demuestra que la gran mayoría de los clientes del conjunto de datos no tienen historial de contacto previo en campañas. A medida que aumenta el número de contactos previos, la frecuencia disminuye de forma drástica, lo que indica que muy pocos clientes fueron contactados una o más veces en campañas anteriores. El gráfico se extiende con una cola larga hacia la derecha, aunque con frecuencias casi imperceptibles, lo que sugiere que hay un número mínimo de clientes con múltiples contactos previos.

Distribución de Frecuencia del previous



Estimación de Densidad del previous



Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "previous" confirman la alta concentración de datos en el valor cero y la extrema asimetría observada en el histograma.

La media es de solo 0.174, lo que es un valor muy bajo y cercano a cero.

La mediana (50%), el primer cuartil (25%) y el tercer cuartil (75%) son todos cero. Esto indica que al menos el 75% de la población no tuvo ningún contacto previo. Esto concuerda perfectamente con la barra de frecuencia más alta del histograma en el valor 0.

El valor mínimo es 0 y el máximo es 7, lo que confirma que el número máximo de contactos previos es muy pequeño en comparación con el tamaño de la muestra.

La desviación estándar (std) es de 0.498, un valor bajo que refleja la escasa dispersión de los datos, con la mayoría de ellos agrupados firmemente en el valor cero.

En conclusión, estas estadísticas demuestran numéricamente que el conjunto de datos está compuesto, en su gran mayoría, por clientes que son contactados por primera vez.


- **Distribución de la tasa de variación del empleo:** El gráfico muestra la distribución de frecuencia de la variable "**emp.var.rate**", que representa la tasa de variación del empleo. La distribución es **multimodal**, lo que significa que tiene varios picos de frecuencia, lo que sugiere que los datos se agrupan en torno a valores específicos y discretos en lugar de seguir una distribución continua.

Se pueden identificar claramente los siguientes picos principales:


- Un pico muy alto en el rango de **+1.1 a +1.4**, que es el valor más frecuente.
- Un pico notable en el rango de **-2.0 a -1.8**, con una frecuencia de alrededor de 9000.
- Picos menores en **-3.4 a -3.2**, **-1.0 a -0.8** y en el valor **0.0**.

Esta distribución no sigue un patrón normal ni simétrico, y su naturaleza multimodal indica que las variaciones del empleo se han agrupado en torno a puntos discretos a lo largo del tiempo, en lugar de variar gradualmente. El pico más alto en los valores positivos indica que la tasa de variación del empleo fue predominantemente alta y positiva durante el período analizado.

Distribución de Frecuencia del emp.var.rate



Estimación de Densidad del emp.var.rate



Algunos de los estadísticos de esta columna son:


Las estadísticas descriptivas de la variable "emp.var.rate" confirman y cuantifican la naturaleza multimodal y no simétrica de la distribución observada en el histograma.


La media de 0.0765 es engañosa. Aunque se encuentra cercana a cero, no representa un valor central típico debido a la distribución. La mediana (50%) es de 1.10, lo que indica que al menos la mitad de las observaciones se encuentran en el pico más alto y positivo de la distribución. La gran diferencia entre la media y la mediana es una fuerte evidencia de que la distribución no es normal y que existen múltiples grupos de valores.

- El rango de los datos va desde un **mínimo** de **-3.4** hasta un **máximo** de **1.4**.
- Los cuartiles (25%, 50%, y 75%) revelan la concentración de los datos. El **25%** de los datos se encuentran en **-1.8 o menos**, lo que corresponde al segundo pico más alto en el histograma.
- Más del **50% de las observaciones** se encuentran en un rango muy estrecho entre **1.1 y 1.4**, lo que confirma que la tasa de variación del empleo fue predominantemente alta y positiva durante el período. El valor de la mediana (1.10) y el tercer cuartil (1.40) están dentro de la misma barra del histograma, lo que indica que la mayor concentración de datos se encuentra en este punto.

Estas estadísticas confirman que las variaciones del empleo no se distribuyen de manera uniforme, sino que se agrupan en clústeres discretos, siendo el más frecuente un aumento positivo de alrededor de 1.1 a 1.4.

- **Distribución del índice de precios al consumidor:** El gráfico muestra la distribución de frecuencia de la variable "cons.price.idx" (índice de precios al consumidor). Al igual que en los gráficos anteriores de variables socioeconómicas, esta distribución es multimodal y tiene picos de frecuencia muy marcados en valores específicos. Se observan picos altos en los valores de 92.8, 93.2, 93.9, 94.1 y 94.4. Esto indica que los datos se agrupan en torno a un número limitado de índices de precios al consumidor, en lugar de seguir una distribución continua o normal. La forma de la distribución sugiere que las observaciones en el conjunto de datos se registraron en momentos en los que el índice de precios al consumidor tenía valores muy específicos. El pico más alto se encuentra alrededor de 93.9 a 94.1, lo que indica que una gran parte de los datos se registraron cuando el índice de precios estaba en ese rango.





Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "cons.price.idx" confirman la concentración de los datos en rangos específicos, lo que apoya el análisis multimodal del histograma. La media (93.57) y la mediana (93.75) son bastante cercanas, lo que sugiere que, a pesar de los picos discretos, el conjunto de datos no está extremadamente sesgado. El rango de los datos va desde un mínimo de 92.20 hasta un máximo de 94.77. Los cuartiles (25%, 50%, y 75%) muestran cómo se distribuyen los valores:

- El **25%** de los datos están en **93.08** o menos.
- La **mediana** (50%) es **93.75**.
- El **75%** de los datos están en **93.99** o menos.


Esto significa que el 50% central de los datos se encuentra entre 93.08 y 93.99, lo que abarca varios de los picos de alta frecuencia observados en el gráfico. La baja desviación estándar (0.579) indica que, a pesar de los picos, la mayoría de los datos se agrupan en un rango relativamente estrecho.


- **Distribución del índice de confianza del consumidor:** El gráfico muestra la distribución de frecuencia de la variable "cons.conf.idx" (índice de confianza del consumidor). Al igual que otros índices socioeconómicos que hemos analizado, esta variable exhibe un patrón multimodal y discreto, con múltiples picos de alta frecuencia.

Los principales grupos de valores se observan en:

- Alrededor de **-46.2 a -46.0**, con un pico de frecuencia notable.
- Entre **-42.7 y -42.0**, con el pico más alto del gráfico.
- Alrededor de **-36.4 y -36.1**, con otro pico de gran altura.

La distribución sugiere que la mayoría de los datos se registraron cuando el índice de confianza del consumidor se encontraba en uno de estos valores específicos y discretos. La forma del gráfico indica que no hubo una variación gradual, sino que las mediciones se agruparon en estos puntos, lo que es típico de datos socioeconómicos que se miden en intervalos de tiempo regulares o que están sujetos a cambios abruptos en respuesta a eventos económicos.





Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "cons.conf.idx" confirman la naturaleza multimodal y la agrupación de datos observada en el histograma. El conteo es de 41,872 observaciones. La media es de -40.40 y la mediana es de -41.80. La diferencia entre la media y la mediana indica que la distribución no es perfectamente simétrica y que hay un ligero sesgo hacia los valores más altos, a pesar de la naturaleza multimodal. La desviación estándar es de 4.62, lo que refleja una dispersión moderada de los datos, a pesar de los grupos discretos de valores. Los valores del índice de confianza del consumidor oscilan entre un mínimo de -50.80 y un máximo de -26.90.

- Los cuartiles proporcionan una visión más detallada de la distribución:
 - El **25%** de los datos se encuentran en **-46.20 o menos**.
 - La **mediana** (50%) es **-41.80**.
 - El **75%** de los datos están en **-36.40 o menos**.

Estos valores confirman que la mayor parte de las observaciones se encuentran en el rango de -46.20 a -36.40, que abarca los picos de alta frecuencia identificados en el histograma. La mediana (-41.80) se encuentra muy cerca del pico central, mientras que los cuartiles se



alinean con los otros picos de frecuencia, reforzando la conclusión de que los datos se agrupan en puntos discretos en lugar de seguir una distribución continua.

Distribución de la tasa de interés de referencia a tres meses: El gráfico muestra la distribución de frecuencia de la variable "euribor3m", que corresponde a la tasa de interés interbancaria de la zona euro a 3 meses. La distribución es marcadamente multimodal y no simétrica, con picos de frecuencia muy definidos en valores específicos.

Los datos se agrupan en torno a los siguientes valores:

- El pico más alto y dominante se encuentra en **5.0%**, con una frecuencia de casi 25,000, lo que indica que esta tasa fue la más común durante el periodo de tiempo analizado.
- Se observa otro pico significativo alrededor de **1.2%**, con una frecuencia de alrededor de 9,000.
- Hay picos menores alrededor de **0.7%** y **4.1%**.

La naturaleza multimodal y la alta concentración en ciertos puntos sugieren que la tasa de interés se mantuvo estable en niveles específicos durante periodos prolongados, en lugar de variar de forma gradual. Esto es típico de las políticas monetarias que ajustan las tasas en pasos discretos.





Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "euribor3m" confirman la naturaleza multimodal y la alta concentración de datos en rangos específicos, tal como se observaba en el histograma. La media es de 3.61, mientras que la mediana es de 4.86. La gran diferencia entre estos dos valores es una prueba contundente de la naturaleza no normal de la distribución. La mediana se encuentra en el pico de mayor frecuencia (alrededor de 4.8-5.0), lo que indica que más de la mitad de los datos se agrupan en este rango, mientras que la media se ve arrastrada hacia abajo por los picos de baja frecuencia y los valores más bajos.

- El rango de la variable va desde un **mínimo** de 0.634 hasta un **máximo** de 5.045.
- Los cuartiles proporcionan una visión más detallada de la concentración de los datos:
 - El **25%** de los datos se encuentran en **1.344 o menos**. Este valor se alinea con el segundo pico más alto del histograma.
 - La **mediana** (50%) es **4.857**.
 - El **75%** de los datos se encuentran en **4.961 o menos**.

La proximidad de la mediana y el tercer cuartil (4.857 y 4.961) demuestra que el 25% de los datos se concentra en un rango muy estrecho. Esto refuerza la conclusión de que la mayor parte de las observaciones se agrupan en el pico más alto, cercano al 5.0%.

- **La distribución del número de empleados:** El gráfico muestra la distribución de frecuencia de la variable "nr.employed" (número de empleados). Esta distribución es multimodal, con los datos agrupados en torno a varios valores discretos en lugar de variar de forma continua. Hay picos de alta frecuencia en los valores de alrededor de 5099, 5190 y 5228. El pico más alto se encuentra en 5228, indicando que este fue el número de empleados más común durante el periodo analizado. Se observan picos más pequeños alrededor de 4960, 5017 y 5046. La naturaleza de la variable (número de empleados) y la forma de la distribución sugieren que las mediciones se tomaron en momentos específicos, con el número de empleados manteniéndose relativamente constante en ciertos niveles durante periodos de tiempo, y luego saltando a otros valores.



Algunos de los estadísticos de esta columna son:

Las estadísticas descriptivas de la variable "nr.employed" (número de empleados) confirman la naturaleza multimodal de la distribución observada en el histograma.


La media es de 5166.88 y la mediana es de 5191.00. Aunque están relativamente cerca, la diferencia se debe a que la media se ve ligeramente arrastrada por los valores más bajos. El rango de los datos es relativamente estrecho, con un mínimo de 4963.6 y un máximo de 5228.1. Esto sugiere que las variaciones en el número de empleados fueron limitadas. La desviación estándar de 72.35 indica una baja dispersión de los datos alrededor de la media, lo cual es de esperar dado que los valores se agrupan en clústeres discretos.

- Los cuartiles muestran la distribución de la frecuencia:
 - El **25%** de los datos se encuentran en **5099.1 o menos**, un valor que se corresponde con el pico de alta frecuencia del histograma.
 - La **mediana** (50%) es **5191.0**, que se encuentra en otro de los picos importantes del gráfico.
 - El **75%** de los datos se encuentran en **5228.1 o menos**, un valor que corresponde al pico más alto del histograma.


Estos datos confirman que la mayor concentración de observaciones se sitúa en los picos de frecuencia, especialmente en el valor 5228.1, donde se ubica el tercer cuartil y el valor máximo.

Distribución de población en función de la latitud: El gráfico muestra la distribución de frecuencia de la variable "latitude", que corresponde a la latitud geográfica. La distribución es notablemente uniforme, lo que significa que las observaciones se distribuyen de manera casi equitativa en todo el rango de valores. A diferencia de las distribuciones anteriores, que tenían picos y sesgos marcados, aquí las barras de frecuencia son de altura muy similar, oscilando entre 1100 y 1300. No hay picos de frecuencia altos ni valles profundos, lo que sugiere que los datos se han recolectado de manera consistente a lo largo de un amplio rango de latitudes, sin una concentración significativa en ninguna región en particular.

Distribución de Frecuencia del latitude



Estimación de Densidad del latitude



Algunos de los estadísticos de esta columna son:


Las estadísticas descriptivas de la variable "latitude" (latitud) confirman la distribución uniforme que se observó en el histograma. La media (36.85) y la mediana (36.76) son valores muy cercanos, lo que indica que no hay un sesgo significativo en la distribución. Esto es un claro indicador de la uniformidad de los datos.

El rango de los datos va desde un mínimo de 24.40 hasta un máximo de 49.38, cubriendo un amplio espectro de latitudes.


La desviación estándar de 7.22 es relativamente alta, lo que refleja que los datos están dispersos en todo el rango y no concentrados alrededor de un valor central, lo cual es la definición de una distribución uniforme.

Los cuartiles (25%, 50% y 75%) se distribuyen de manera casi equitativa en el rango. La distancia entre el 25% (30.62) y la mediana (36.76) es similar a la distancia entre la mediana y el 75% (43.10), lo que confirma que no hay una concentración de datos en ninguna región particular. Los datos se distribuyen uniformemente a lo largo de las latitudes, como si se hubieran seleccionado aleatoriamente de un rango geográfico sin priorizar ninguna zona específica.


Estudio de la columna de trabajos: El gráfico circular muestra la distribución de una población según su ocupación, revelando la estructura laboral del conjunto de datos analizado. La categoría más grande es "admin." (administración), que representa una porción significativa del 25.5%. Le siguen de cerca las ocupaciones de "blue-collar" (obreros), con un 22.7%, y los "technician" (técnicos), con un 16.5%. En conjunto, estos tres segmentos representan casi dos tercios de la muestra, destacando la predominancia de roles administrativos, manuales y técnicos. En el otro extremo, las categorías de "student" (estudiantes), "unemployed" (desempleados), "housemaid" (amas de casa), "self-employed" (autónomos) y "entrepreneur" (emprendedores) representan las porciones más pequeñas, con porcentajes entre el 2.1% y el 3.6%, lo que indica que estas ocupaciones son minoritarias en esta población específica. La distribución muestra una concentración de la fuerza laboral en roles estructurados y de alta demanda, con una menor representación de roles no tradicionales o en etapas de transición.




Estudio del estado civil de la muestra: El gráfico circular representa la distribución del estado civil de una muestra, donde se observa que la mayoría de los individuos están casados (60.5%). El segundo grupo más grande corresponde a las personas solteras (28.3%), seguido por el grupo de divorciados, que constituye la porción más pequeña (11.3%). Esta visualización permite identificar rápidamente la mayor concentración de datos en la categoría "married", indicando que este es el estado civil predominante en la población analizada. La clara desproporción entre las categorías sugiere que el matrimonio es un estado significativamente más común que el de soltero o divorciado dentro de la muestra.



Estudio del nivel educativo de la población: El gráfico circular muestra la distribución del nivel educativo de una muestra de personas. Se observa que el grupo más grande tiene un título universitario (30.9%). Le sigue la educación secundaria ("high.school") con un 24.2% y el ciclo básico de nueve años ("basic.9y") con un 15.4%. El resto de las categorías educativas, como el curso profesional, el ciclo básico de cuatro años, el ciclo básico de seis años y el analfabetismo, representan porcentajes menores, siendo la categoría de analfabetismo ("illiterate") la que presenta el menor porcentaje (0.0%). Esta distribución refleja que, dentro de la muestra, el nivel educativo más común es el universitario.




Estudio del medio de comunicación: El gráfico circular representa la distribución de los tipos de contacto telefónico utilizados en una muestra. Se observa que el teléfono móvil ("cellular") es el medio de contacto predominante, con un 63.8%, mientras que el teléfono fijo ("telephone") representa el 36.2%. Esta visualización resalta la clara preferencia por el uso de dispositivos móviles como principal canal de comunicación en la población analizada, lo que refleja la tendencia actual hacia la movilidad y la conectividad personal.



Estudio de la gente que está suscrita: El gráfico circular representa la distribución de la suscripción a un servicio. La gran mayoría de la muestra, un 88.8%, no está suscrita, lo que corresponde a la categoría "no". Solo un 11.2% de los individuos en la muestra sí está suscrito al servicio. La visualización muestra una clara asimetría en la que la inmensa mayoría de la población analizada no utiliza el servicio de suscripción.

Distribución




Matriz de correlaciones: Esta es una matriz de correlaciones que visualiza las relaciones entre varias variables numéricas. Los valores de correlación van de -1 a 1, donde 1 indica una correlación positiva perfecta, -1 una correlación negativa perfecta y 0 no hay correlación. El color de cada celda refuerza el valor numérico: los colores rojos indican correlaciones positivas, los azules indican correlaciones negativas, y los colores grises o blancos sugieren una correlación cercana a cero.

Basado en la matriz, aquí hay algunas de las relaciones más fuertes y más débiles:

- **Correlación Positiva Fuerte:**
 - euribor3m y emp.var.rate: Con un valor de 0.96, estas dos variables tienen una correlación extremadamente fuerte. Esto sugiere que a medida que una aumenta, la otra casi siempre aumenta de manera proporcional. Esto es común en variables macroeconómicas que se mueven en tándem.
 - nr.employed y emp.var.rate: Con un valor de 0.93, también muestran una correlación positiva muy fuerte. Esto podría indicar que el número de empleados y la tasa de variación del empleo tienen un comportamiento similar.
- **Correlación Negativa Fuerte:**
 - euribor3m y cons.price.idx: Con un valor de -0.96, hay una correlación negativa extremadamente fuerte. Esto significa que a medida que el euribor (un tipo de interés) sube, el índice de precios al consumidor tiende a bajar de manera casi perfecta, lo cual es inusual y podría merecer una revisión más detallada de los datos o las variables.
 - nr.employed y cons.price.idx: Con un valor de -0.95, esta pareja también tiene una correlación negativa muy fuerte.
- **Correlaciones Débiles o Nulas:**
 - La mayoría de las variables como default, housing, loan, duration, campaign, latitude y longitude muestran valores de correlación muy cercanos a cero con el resto de las variables. Esto indica que estas variables son en gran medida independientes entre sí, al menos en términos de una relación lineal.

En resumen, la matriz muestra un alto grado de multicolinealidad entre las variables macroeconómicas (emp.var.rate, cons.price.idx, euribor3m y nr.employed), lo que es una consideración importante si se utilizan en modelos predictivos, ya que variables altamente correlacionadas pueden causar problemas de estabilidad. Por otro lado, las variables relacionadas con el cliente (housing, loan, campaign, etc.) parecen no tener una relación lineal significativa con ninguna de las otras variables en el conjunto de datos.




Análisis bivariado: Estos gráficos de caja (boxplot) muestran la distribución de la Edad y la Duración de una llamada para dos grupos: aquellos que se suscribieron ("yes") y aquellos que no lo hicieron ("no"). Los diagramas de caja son útiles para comparar la mediana, los cuartiles y la presencia de valores atípicos.

El gráfico de la izquierda muestra que la distribución de la Edad es notablemente similar entre ambos grupos. La mediana (la línea horizontal dentro de la caja) es casi la misma para quienes se suscribieron y quienes no. El rango intercuartílico (el ancho de la caja) también es muy parecido. Esto indica que la edad por sí sola no es un factor diferenciador significativo para determinar si una persona se suscribe o no. Hay valores atípicos (los puntos por encima y por debajo de los bigotes) en ambos grupos, pero su distribución no varía considerablemente.

El gráfico de la derecha, sin embargo, revela una diferencia considerable en la distribución de la Duración de la llamada.

- Grupo 'no' (no suscritos): La mediana de la duración de la llamada es relativamente baja, alrededor de los 250 segundos. Esto sugiere que la mayoría de las llamadas que no resultaron en una suscripción fueron bastante cortas.
- Grupo 'yes' (suscritos): La mediana de la duración de la llamada es significativamente mayor, alrededor de los 500 segundos. Esto indica que las llamadas que sí resultaron en una suscripción tienden a ser mucho más largas.


Esta diferencia es clave y demuestra una fuerte relación entre la duración de la llamada y la suscripción. Las llamadas más largas parecen ser un indicador importante de una mayor probabilidad de que el cliente termine suscribiéndose. Los valores atípicos en ambos grupos muestran llamadas extremadamente largas, pero el patrón general de la distribución es claro y distintivo entre las dos categorías.



Ahora vamos relacionar los datos del archivo Excel:


Distribución de renta por número de niños en casa: El gráfico de violín muestra la distribución del ingreso ('Income') en relación con el número de niños en casa ('Número de niños en casa'). A primera vista, se observa que la forma de las tres distribuciones es sorprendentemente similar. El violín del grupo con 0 niños, 1 niño y 2 niños en casa tiene una forma y anchura casi idénticas, lo que sugiere que el número de niños en el hogar no tiene un impacto significativo en la distribución general del ingreso. Las cajas internas en cada violín, que representan el rango intercuartílico (IQR), son también muy parecidas, lo que indica que la mediana y la variabilidad de los ingresos son consistentes en los tres grupos. En resumen, basándose en este gráfico, no hay una evidencia clara de que tener 0, 1 o 2 niños en casa se correlacione con un patrón de ingreso distinto. La distribución de los

ingresos parece ser independiente de esta variable.



Distribución de renta por número de adolescentes en casa: El gráfico de violín que se muestra compara la distribución del ingreso ('Income') basándose en el número de adolescentes en casa ('Número de pubertos en casa'). Un gráfico de violín combina un diagrama de caja con un gráfico de densidad de kernel, lo que permite visualizar no solo la mediana y los cuartiles, sino también la forma completa de la distribución de los datos. Al analizar este gráfico, se observa que las tres distribuciones (para 0, 1 y 2 adolescentes) son muy similares. La forma de los "violines" es casi idéntica, con una alta concentración de datos en el rango de ingresos medios, y colas que se extienden de manera similar hacia ingresos más altos y más bajos. La caja interna, que muestra el rango intercuartílico (IQR) y la mediana, es prácticamente indistinguible entre los tres grupos. La línea de la mediana se encuentra en un valor similar en todos los casos, lo que sugiere que el ingreso central no

cambia significativamente.



Informe explicativo del análisis

Preparación y Manejo de Datos

El análisis exploratorio de datos (EDA) se realizó después de un proceso de preparación de los datos para asegurar que estuvieran en un formato adecuado. Se llevaron a cabo las siguientes operaciones de preprocesamiento:

- Manejo de Valores Nulos: Se eliminaron las columnas con más del 2% de datos nulos. Para la columna
- 'default', los valores nulos se trataron como verdaderos, basándose en la suposición de que el resto de datos no nulos tenían un valor cero. Los valores nulos de la columna
- 'euribor3m' se sustituyeron por el valor inmediatamente superior, siguiendo un patrón decreciente de los valores no nulos. Para la columna
- 'age', se aplicaron condiciones específicas para imputar los valores nulos según el estado civil ('marital') y la educación, como asignar edades entre 22 y 30 años a individuos 'SINGLE'. Es importante destacar que estas operaciones se realizaron solo en el archivo CSV, ya que el archivo de Excel no contenía datos nulos.
- Manejo de Datos Corruptos: Se reemplazaron las variables no numéricas por numéricas.

- Creación del Nuevo Data Frame: Se generó un nuevo archivo CSV para el estudio posterior.
-

Análisis Exploratorio de Variables Clave

El análisis se centró en varias variables numéricas y cualitativas para entender sus distribuciones y características.

Distribución de la Edad (age)

La variable age muestra una asimetría positiva (sesgada a la derecha), lo que significa que la mayoría de los datos se concentran en las edades más jóvenes y de mediana edad.

- La mayor concentración se encuentra entre los 25 y 60 años, con un pico notable entre los 30 y 40 años. A partir de los 40, la frecuencia disminuye progresivamente.
 - La media es de aproximadamente 41.09 años, mientras que la mediana es de 39.00 años. La diferencia entre la media y la mediana confirma la asimetría positiva, ya que los valores más altos arrastran el promedio hacia arriba.
 - El rango de edad abarca desde un mínimo de 17 años hasta un máximo de 98 años.
 - Los cuartiles indican que el 50% central de la población se encuentra en el rango de 32 a 48 años, lo que confirma que la muestra está predominantemente compuesta por adultos jóvenes y de mediana edad.
-

Distribución de la Duración de la Llamada (duration)

La variable duration presenta una asimetría positiva extrema, con la mayoría de las interacciones muy cortas, cercanas a cero segundos.

- La media es de 257.69 segundos, mientras que la mediana es de 179.00 segundos. La gran diferencia entre estos dos valores se debe a un pequeño número de llamadas de muy larga duración que arrastran la media hacia arriba.
 - El rango va desde un mínimo de 0.00 segundos hasta un máximo de 4918.00 segundos (más de 81 minutos).
 - El 50% central de las interacciones se encuentra entre 102 y 319 segundos. Esto refuerza que la mayoría de las interacciones son relativamente cortas.
-

Distribución del Número de Contactos de Campaña (campaign)

La variable campaign también muestra una fuerte asimetría positiva.

- La gran mayoría de los clientes (el 75%) solo fueron contactados hasta tres veces o menos.
- El valor más frecuente es 1, lo que indica que la mayoría de los clientes solo fueron contactados una vez.

- El rango de contactos va desde un mínimo de 1 hasta un máximo de 56.
 - La media (2.56) es significativamente mayor que la mediana (2.00) debido a la existencia de un pequeño número de clientes contactados muchas veces.
-

Distribución del Número de Contactos Previos (previous)

Esta variable tiene un sesgo positivo extremadamente pronunciado, ya que la gran mayoría de los clientes no fueron contactados previamente en campañas anteriores.

- La media es muy baja (0.174), y tanto la mediana como el 25% y 75% de los cuartiles son cero. Esto confirma que al menos el
 - 75% de la población no tuvo ningún contacto previo.
 - El rango de contactos previos va de 0 a 7.
 - La baja desviación estándar (0.498) refleja que los datos se agrupan firmemente en el valor cero.
-

Análisis de Variables Cualitativas

El análisis del estado civil, el nivel educativo y el medio de comunicación revela la composición de la muestra:

- Estado Civil: El grupo predominante es el de personas casadas (60.5%), seguido por las solteras (28.3%) y divorciadas (11.3%).
 - Nivel Educativo: El nivel educativo más común es el de título universitario (30.9%), seguido por la educación secundaria (24.2%) y el ciclo básico de nueve años (15.4%).
 - Medio de Comunicación: El teléfono móvil (63.8%) es el medio de contacto predominante, lo que refleja una clara preferencia por los dispositivos móviles.
 - Suscripción al Servicio: Solo un 11.2% de la muestra está suscrita al servicio, mientras que un 88.8% no lo está, lo que muestra una clara asimetría en la tasa de suscripción.
-

Correlación y Análisis Bivariado

Matriz de Correlaciones

La matriz de correlaciones numéricas mostró algunas relaciones clave.

- Correlaciones Positivas Fuertes:
 - euribor3m y emp.var.rate: Con un valor de 0.96, esta es una correlación extremadamente fuerte. Sugiere que ambas variables macroeconómicas se mueven en la misma dirección.
 - nr.employed y emp.var.rate: Con un valor de 0.93, también tienen una correlación positiva muy fuerte.
- Correlación entre Variables:

- Edad (age) y Suscripción: El análisis bivariado con boxplots (diagramas de caja) indica que la distribución de la edad es notablemente similar entre los grupos que se suscribieron (yes) y los que no (no). Esto sugiere que
 - la edad no es un factor diferenciador significativo para la suscripción.
 - Duración (duration) y Suscripción: Por el contrario, la duración de la llamada muestra una diferencia considerable entre los dos grupos. Las llamadas más largas se correlacionan con una mayor probabilidad de que el cliente se suscriba, lo que lo convierte en un
 - indicador clave para predecir la suscripción.
 - **Renta e Impacto de Hijos/Adolescentes:** Los gráficos de violín que comparan el ingreso (Income) con el número de niños y adolescentes en casa (Número de niños en casa y Número de pubertos en casa) muestran que las distribuciones son sorprendentemente similares en todos los grupos. Esto sugiere que el número de niños o adolescentes no tiene un impacto significativo en la distribución general del ingreso.
-

Conclusiones y Posibles Mejoras

Observaciones y Conclusiones Clave

- **Asimetría en la Mayoría de las Variables:** La mayoría de las variables clave (age, duration, campaign, previous) muestran una fuerte asimetría positiva, lo que indica que los datos están concentrados en el extremo inferior de sus rangos.
- **Duración de la Llamada como Indicador Clave:** La duración de la llamada es el factor más prometedor para predecir la suscripción.
- **Variables Socioeconómicas como Clústeres:** Variables como emp.var.rate, cons.price.idx, cons.conf.idx y euribor3m son multimodales, lo que sugiere que los datos se recopilaron en puntos de tiempo discretos donde las condiciones económicas eran estables en ciertos valores.
- **No Relevancia de Ciertas Variables:** La edad y el número de niños/adolescentes en casa no parecen ser factores importantes para predecir la suscripción o la distribución de los ingresos.

Posibles Mejoras

- **Análisis Multivariado Avanzado:** Si bien se realizó un análisis bivariado, sería útil explorar interacciones más complejas. Por ejemplo, ¿hay alguna combinación de variables (ej. edad y duración) que pueda predecir la suscripción de manera más efectiva?
- **Creación de Nuevas Variables (Feature Engineering):** Se podrían crear nuevas variables a partir de las existentes. Por ejemplo, agrupar las edades en rangos más definidos o crear una variable que clasifique las interacciones por su duración (corta, media, larga).
- **Manejo de Datos Faltantes:** Aunque se manejaron los datos nulos, las suposiciones hechas (como tratar los nulos en default como True) podrían ser revisadas o validadas con un análisis más riguroso para evitar sesgos. Métodos más

avanzados como la imputación por regresión o el uso de algoritmos de Machine Learning podrían ser considerados.

- **Análisis Temporal:** El documento menciona que las variables socioeconómicas tienen picos discretos. Sería valioso incorporar un análisis temporal (si los datos de fecha y hora están disponibles) para entender cómo evolucionaron estas variables y si los cambios en el tiempo se correlacionan con la tasa de suscripción.
- **Análisis de Outliers:** Aunque se mencionan los valores atípicos (outliers), un análisis más profundo para determinar su causa y si deben ser eliminados o transformados podría ser beneficioso, especialmente para la variable duration, que tiene valores extremos muy altos.

