

EDA PROYECTO FINAL



Manejo y Estructura de los Archivos CSV

El análisis de datos para este proyecto se basa en el manejo y la integración de **archivos separados por comas (CSV)**, que contienen información detallada del Censo de 2015. El corpus principal de datos, denominado originalmente `acs2015_census_tract_data.csv`, ha sido dividido y depurado en dos archivos fundamentales a nivel de **tracto censal**: `Hoja_de_datos_UNO_depurado.csv` y `Hoja_de_datos_DOS_depurado.csv`.

Archivos por Tracto Censal: Desglose Detallado

Los archivos a nivel de tracto censal comparten una clave de identificación (`CensusTract`) y contienen una gran cantidad de registros, proporcionando una vista granular de las estadísticas demográficas y socioeconómicas.

Hoja_de_datos_UNO_depurado.csv

Este *DataFrame* incluye **72,901 registros** completos y se enfoca en métricas de población y composición racial/étnica:

- **Identificación y Ubicación:** `CensusTract`, `State`, y `County`.
- **Demografía General:** `TotalPop`, `Men`, y `Women`.
- **Composición Étnica y Racial (Porcentajes):** `Hispanic`, `White`, `Black`, `Native`, `Asian`, y `Pacific`.
- **Estatus de Ciudadanía e Ingresos:** `Citizen` (población mayor de 18 años, entero) e `Income` (ingreso medio del hogar, flotante).

Columnas Clave	Descripción	Tipo de Dato
<code>CensusTract</code>	Identificador único del tracto censal.	<code>int64</code>
<code>TotalPop</code>	Población total en el tracto.	<code>int64</code>
<code>Hispanic</code>	Porcentaje de población hispana.	<code>float64</code>
<code>Income</code>	Ingreso medio del hogar.	<code>float64</code>

Hoja_de_datos_DOS_depurado.csv

Este archivo complementa la información con **72,727 registros** (ligeramente menos que `Hoja_de_datos_UNO`) y se centra en los indicadores económicos, de pobreza, ocupacionales y de transporte:

- **Ingresos y Pobreza:** Incluye errores de margen (`IncomeErr`, `IncomePerCapErr`), `IncomePerCap` (ingreso per cápita), `Poverty` (tasa de pobreza) y `ChildPoverty` (tasa de pobreza infantil).
- **Ocupación por Categoría (Porcentajes):** `Professional`, `Service`, `Office`, `Construction`, y `Production`.
- **Medios de Transporte al Trabajo (Porcentajes):** `Drive`, `Carpool`, `Transit`, `Walk`, `OtherTransp`, y `WorkAtHome`.
- **Indicadores Laborales:** `MeanCommute` (tiempo medio de viaje), `Employed` (población empleada), y distribución del empleo (`PrivateWork`, `PublicWork`, `SelfEmployed`, `FamilyWork`), finalizando con la tasa de `Unemployment`.

Columnas Clave	Descripción	Tipo de Dato
<code>IncomePerCap</code>	Ingreso medio per cápita.	<code>float64</code>
<code>Poverty</code>	Tasa de pobreza.	<code>float64</code>
<code>Professional</code>	Porcentaje en ocupaciones profesionales.	<code>float64</code>
<code>Unemployment</code>	Tasa de desempleo.	<code>float64</code>

Archivo a Nivel de Condado: Vista Agregada

Adicionalmente, se maneja un tercer archivo, `df_2015_depurado.csv` (originado probablemente del archivo `2015_country` mencionado en el texto), que proporciona los mismos indicadores pero a un nivel de agregación **por condado**.

`df_2015_depurado.csv`

Este *DataFrame* contiene **3,218 registros**, uno por cada condado en el conjunto de datos, y consolida todas las 37 métricas presentes en los dos archivos de tracto censal.

- **Integración:** Este archivo es el resultado de una agregación o unión previa, ya que incluye la combinación de todas las columnas de `Hoja_de_datos_UNO` y `Hoja_de_datos_DOS`, utilizando `CensusId` como clave principal a nivel de condado.

- **Consistencia:** Las columnas como `TotalPop`, `Income`, `Poverty`, `Employed`, etc., reflejan los valores agregados o promediados para cada condado, proporcionando una perspectiva macro de los datos.

La estructura de datos implica que es posible realizar análisis tanto a un nivel geográfico detallado (tracto censal) como a un nivel más general (condado), permitiendo comparaciones entre la distribución dentro de los condados y las métricas a nivel de condado.

Manejo de datos nulos

En este trabajo se han eliminado aquellos datos nulos que no superen el 2% de los datos. Por suerte, este dataset cumplía ese requisito en todas las columnas, así pues el problema del nulo está resuelto, ¡Y a la primera!

Manejo de datos corruptos

Vemos los tipos de datos que tenemos en las tablas, para discernir si tenemos que cambiar algo o no.



```
df_bank_UNO_limpio.info()
```



```
<class 'pandas.core.frame.DataFrame'>
```

```
Index: 72901 entries, 0 to 74000
```

```
Data columns (total 14 columns):
```

#	Column	Non-Null Count	Dtype
0	CensusTract	72901 non-null	int64
1	State	72901 non-null	object
2	County	72901 non-null	object
3	TotalPop	72901 non-null	int64
4	Men	72901 non-null	int64
5	Women	72901 non-null	int64
6	Hispanic	72901 non-null	float64
7	White	72901 non-null	float64
8	Black	72901 non-null	float64
9	Native	72901 non-null	float64
10	Asian	72901 non-null	float64
11	Pacific	72901 non-null	float64
12	Citizen	72901 non-null	int64
13	Income	72901 non-null	float64

```
dtypes: float64(7), int64(5), object(2)
```

```
memory usage: 8.3+ MB
```

 df_bank_DOS_limpio.info()

 <class 'pandas.core.frame.DataFrame'>

Index: 72727 entries, 0 to 74000

Data columns (total 23 columns):

#	Column	Non-Null Count	Dtype
0	IncomeErr	72727 non-null	float64
1	IncomePerCap	72727 non-null	float64
2	IncomePerCapErr	72727 non-null	float64
3	Poverty	72727 non-null	float64
4	ChildPoverty	72727 non-null	float64
5	Professional	72727 non-null	float64
6	Service	72727 non-null	float64
7	Office	72727 non-null	float64
8	Construction	72727 non-null	float64
9	Production	72727 non-null	float64
10	Drive	72727 non-null	float64
11	Carpool	72727 non-null	float64
12	Transit	72727 non-null	float64
13	Walk	72727 non-null	float64
14	OtherTransp	72727 non-null	float64
15	WorkAtHome	72727 non-null	float64
16	MeanCommute	72727 non-null	float64
17	Employed	72727 non-null	int64
18	PrivateWork	72727 non-null	float64
19	PublicWork	72727 non-null	float64
20	SelfEmployed	72727 non-null	float64
21	FamilyWork	72727 non-null	float64
22	Unemployment	72727 non-null	float64

dtypes: float64(22), int64(1)

memory usage: 13.3 MB

```
df_2015_limpio.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 3218 entries, 0 to 3219
Data columns (total 37 columns):
#   Column                Non-Null Count  Dtype
---  -
0   CensusId              3218 non-null   int64
1   State                 3218 non-null   object
2   County               3218 non-null   object
3   TotalPop             3218 non-null   int64
4   Men                  3218 non-null   int64
5   Women                3218 non-null   int64
6   Hispanic              3218 non-null   float64
7   White                3218 non-null   float64
8   Black                3218 non-null   float64
9   Native               3218 non-null   float64
10  Asian                3218 non-null   float64
11  Pacific              3218 non-null   float64
12  Citizen              3218 non-null   int64
13  Income               3218 non-null   float64
14  IncomeErr            3218 non-null   float64
15  IncomePerCap         3218 non-null   int64
16  IncomePerCapErr      3218 non-null   int64
17  Poverty              3218 non-null   float64
18  ChildPoverty         3218 non-null   float64
19  Professional         3218 non-null   float64
20  Service              3218 non-null   float64
21  Office               3218 non-null   float64
22  Construction         3218 non-null   float64
23  Production           3218 non-null   float64
24  Drive                3218 non-null   float64
25  Carpool              3218 non-null   float64
26  Transit              3218 non-null   float64
27  Walk                 3218 non-null   float64
28  OtherTransp          3218 non-null   float64
29  WorkAtHome           3218 non-null   float64
30  MeanCommute          3218 non-null   float64
31  Employed             3218 non-null   int64
32  PrivateWork          3218 non-null   float64
33  PublicWork           3218 non-null   float64
34  SelfEmployed         3218 non-null   float64
35  FamilyWork           3218 non-null   float64
36  Unemployment         3218 non-null   float64
dtypes: float64(27), int64(8), object(2)
memory usage: 955.3+ KB
```

Parece que todo está en orden, pero para asegurarnos debemos imprimir un cierto número de valores de cada columna para ver si hay valores no correspondidos como NaN.

Después del análisis, se ve que no hay ninguna corrupción. No se ha impreso la info en este documento ya que es infinita...

Creación de los nuevos archivos de datos

Una vez que hemos eliminado los datos nulos y transformado de modo adecuado y coherente las variables de los elementos de las tuplas del archivo, creamos los nuevos archivos tras esta limpieza.

Expresión de los datos

Se ha desglosado la información de distintos aspectos con salidas de texto y se han planteado distintos gráficos y distribuciones para la visualización y el bien entendimiento de los datos que tenemos en los archivos.

Se ha sobrepuesto en las distribuciones de datos una suavización de las curvas de la muestra para poder entender mejor la evolución de la población en el marco estadístico.

También se ha catalogado cada sección para una mejor separación entre las secciones, así mismo con títulos y subtítulos en todo el cuaderno Jupyter.

Análisis exploratorio de los datos (EDA)

Expresión del código del análisis:

Este código ejecuta una serie de cálculos y pruebas estadísticas sobre un conjunto de datos poblacionales (denominado `df`), con el objetivo de explorar las relaciones entre variables como ingresos, pobreza, demografía (etnia, género) y empleo. La metodología se basa en la Estadística Descriptiva para resumir los datos y la Estadística Inferencial para probar hipótesis.

Introducción y Preparación de Datos

El inicio del código establece el entorno de trabajo, esencialmente preparando las "herramientas" matemáticas:

- `import pandas as pd, import numpy as np`: Se importan librerías que actúan como "calculadoras avanzadas" para manejar grandes tablas de números (matrices y DataFrames) y realizar operaciones algebraicas rápidas.
- `import matplotlib.pyplot as plt, import seaborn as sns`: Herramientas para crear representaciones gráficas (gráficos de barras, histogramas, etc.) de los resultados numéricos.
- `from scipy import stats, import statsmodels.api as sm, from statsmodels.formula.api import ols`: Son colecciones de pruebas estadísticas formales, como la Prueba T, la correlación de Pearson y la Regresión Lineal.

Asunción de Carga de Datos: Se asume que la tabla principal de datos, `df_2015_limpio`, ya existe y es la base de todos los cálculos, renombrada como `df`.

A. Desigualdad de Ingresos y Pobreza

Esta sección se centra en la descripción y comparación de las medidas de riqueza.

Análisis Descriptivo (Resúmenes de Números)

1. Ingreso Promedio por Estado y Condado:
 - Cálculo: Se aplica la **Media Aritmética ($\bar{x}$)** para las columnas Income (Ingreso Promedio) y IncomePerCap (Ingreso Per Cápita) después de agrupar los registros por State (Estado) y, adicionalmente, por County (Condado).
 - Propósito: Identificar las regiones (Estados y Condados) donde la suma de los ingresos dividida por el número de observaciones es mayor, sirviendo como una medida de tendencia central de la riqueza.
 - Filtro (.head()): Se muestran solo los 5 valores más altos, que son los promedios de ingreso más altos observados.
 2. Distribución de Variables de Ingreso y Error:
 - Cálculo: La función describe() produce un resumen estadístico de las variables de ingreso (Income, IncomePerCap) y sus márgenes de error (IncomeErr, IncomePerCapErr).
 - Métricas: Incluye:
 - Conteo (N): El número total de observaciones.
 - Media ($\bar{x}$): El promedio.
 - Desviación Estándar (σ): Una medida de la dispersión de los datos alrededor de la media; indica qué tan típicos son los valores.
 - Mínimo y Máximo: Los valores extremos.
 - Cuartiles (25%, 50% - Mediana, 75%): Valores que dividen el conjunto de datos ordenado en cuatro partes iguales, revelando la asimetría de la distribución.
 - Visualización (sns.histplot): Se generan Histogramas, que son gráficos de frecuencia que muestran cómo se distribuyen los valores de ingreso (su forma). La línea KDE (Estimación de la Densidad del Núcleo) es una versión suavizada del histograma que aproxima la función de densidad de probabilidad subyacente.
-

Análisis Estadístico (Pruebas de Hipótesis y Relaciones)

1. Correlación entre Ingreso y Pobreza:
 - Cálculo: Se utiliza el Coeficiente de Correlación de Pearson (r) para medir la fuerza y dirección de la relación lineal entre las variables de ingreso (Income, IncomePerCap) y las de pobreza (Poverty, ChildPoverty).
 - Interpretación: El valor de r varía entre -1 y +1.
 - Un r cercano a -1 indica una fuerte relación inversa: a mayor ingreso, menor pobreza.
 - Un r cercano a 0 indica una relación lineal muy débil o nula.

- Condición: Se evalúa si el valor absoluto de r es mayor a 0.7, lo que se considera una correlación "fuerte".
 - 2. Prueba T para Comparar Ingresos Promedio (Prueba de Hipótesis):
 - Objetivo: Determinar si la media poblacional (μ) de los ingresos en un grupo de Estados (el Grupo 1) es significativamente diferente de la media de ingresos en otro grupo de Estados (el Grupo 2).
 - Paso 1: Prueba de Levene (Igualdad de Varianzas):
 - Hipótesis Nula (H_0): Las varianzas (σ^2) de los ingresos en el Grupo 1 y el Grupo 2 son iguales.
 - Propósito: La Prueba T requiere saber si las varianzas son iguales para elegir la fórmula correcta. Se calcula un p-valor: si $p < 0.05$, se rechaza H_0 y se asume que las varianzas son desiguales.
 - Paso 2: Prueba T de Muestras Independientes:
 - Hipótesis Nula (H_0): No hay diferencia entre las medias ($\mu_1 = \mu_2$).
 - Estadístico T: Mide la diferencia entre las medias de los grupos en términos de la variabilidad de los datos.
 - p-valor: La probabilidad de observar una diferencia tan extrema como la encontrada, asumiendo que H_0 es verdadera. Si el p-valor es menor que 0.05, se rechaza H_0 y se concluye que la diferencia de ingresos promedio es estadísticamente significativa.
-

B. Demografía y Etnia

Esta sección analiza la composición de la población.

1. Proporción Ponderada de Grupos Étnicos:
 - Cálculo: Se determina la proporción de cada grupo étnico por Estado, pero ponderando por la población total (TotalPop) de cada Condado.
 - Propósito: Evitar que los condados pequeños tengan un peso desproporcionado en el promedio estatal. El resultado es una proporción a nivel estatal más precisa.
 2. Ratio de Género:
 - Cálculo: Se calcula la razón (o ratio) entre el total de hombres y el total de mujeres para cada Estado
 - Propósito: Determinar el desequilibrio de género en la población. Un valor mayor que 1 indica que hay más hombres que mujeres.
 3. Correlación (Pearson r) entre Composición Étnica, Ingresos y Desempleo:
 - Cálculo: Se calcula el Coeficiente de Correlación de Pearson (r) para ver si una mayor proporción de un grupo étnico (ej., % Black o % Asian) está linealmente asociada con tasas de Unemployment (Desempleo) o IncomePerCap (Ingreso Per Cápita).
-

C. Empleo y Sector Laboral

Esta sección investiga las dinámicas del mercado de trabajo.

Análisis Descriptivo

1. Tasas Promedio de Desempleo: Se calcula la Media Aritmética ($\bar{x}$) de la tasa de Unemployment por Estado y Condado, para identificar los lugares con mayor (o menor) incidencia de desempleo.
2. Distribución del Tipo de Empleo: Se calcula la Media Aritmética ($\bar{x}$) de los porcentajes de empleo en diferentes sectores (Professional, Service, etc.) para obtener una visión general de la composición laboral.

Análisis Estadístico

1. Modelo de Regresión Lineal Simple: Desempleo ($\hat{Y}$) vs. Pobreza (X)
 - Objetivo: Cuantificar la relación lineal predictiva entre la Pobreza (X , variable independiente) y el Desempleo (Y , variable dependiente).
 2. Comparación de Ingresos (Mediana) - Prueba de Kruskal-Wallis:
 - Objetivo: Comparar las medianas de los ingresos en condados con un alto porcentaje de empleo Professional frente a condados con alto empleo Production. Es una alternativa no paramétrica a la ANOVA, utilizada cuando no se cumplen los supuestos de normalidad o igualdad de varianzas.
 - Hipótesis Nula (H_0): Las medianas de los ingresos son iguales en todos los grupos.
 - Estadístico H: Se basa en el rango (posición ordenada) de los datos, no en sus valores reales, por lo que es robusto a valores atípicos.
 - p-valor: Si $p < 0.05$, se rechaza H_0 y se concluye que hay una diferencia significativa en la mediana de los ingresos entre los grupos.
-

D. Movilidad y Desplazamiento

Esta sección analiza las variables relacionadas con el viaje al trabajo.

Análisis Descriptivo

1. Distribución del Tiempo de Viaje Promedio (MeanCommute): Se utiliza la función describe() para obtener la media, desviación estándar, y cuartiles de los minutos de viaje. Se visualiza con un Histograma para entender la concentración de los tiempos de desplazamiento.
2. Modos de Transporte: Se calcula la Media Aritmética ($\bar{x}$) del porcentaje de personas que utilizan diferentes modos de transporte (Drive, Transit, etc.) por Estado.

Análisis Estadístico

1. Correlación (Pearson r) entre Uso de Transporte Público (Transit) e Ingreso Per Cápita (IncomePerCap):

- Cálculo: Se mide la fuerza y dirección de la relación lineal entre el uso del transporte público y el ingreso.
- Propósito: Determinar si los Estados o Condados con mayor dependencia del transporte público tienden a tener un Ingreso Per Cápita más alto (o más bajo), y cuantificar esa asociación con el Coeficiente r .

Este proceso de análisis estadístico y matemático permite al usuario obtener conclusiones objetivas sobre las relaciones socioeconómicas en el conjunto de datos, yendo más allá de una simple lectura de los números.

Expresión del código del dashboard:

Antes de nada, decir que he tenido dificultades con Google Sheets para hacer el dashboard, se quedaba colgado... No sé porqué... no debería... pero no he tenido más remedio que hacerlo con Python. Francamente, espero que no importe.

Para dar fé, dejaré el código anexo al cuaderno.

La explicación de su funcionamiento es el siguiente:

Comprendido. Procederé a dar una explicación detallada y completamente narrada, libre de jerga informática, puntos de viñeta o tablas, enfocándome en el propósito práctico del código, tal como me lo has solicitado.

Este código es el motor de una aplicación web interactiva, un Dashboard Socioeconómico, diseñado para cargar, combinar y visualizar información clave sobre áreas geográficas como el ingreso, el desempleo y la pobreza. Imagina que estás construyendo un panel de control avanzado que toma varios archivos de hojas de cálculo y los convierte en gráficos y estadísticas fáciles de explorar en una página de internet.

Inicio y Preparación del Entorno

Al comienzo, el código hace los preparativos iniciales. Lo primero es llamar a sus herramientas. Se invoca a Pandas, que es la herramienta fundamental para manejar y manipular las tablas de datos, como si fuera un gestor experto de hojas de cálculo. Luego, se llama a Plotly Express, el pintor que creará los gráficos y visualizaciones interactivas. La herramienta más importante es Streamlit, que actúa como el constructor, tomando todo el código y levantando la página web interactiva. Finalmente, se incluye una herramienta para manejar las carpetas y los nombres de los archivos.

Una vez que las herramientas están listas, el código configura la página. Le da un título al tablero, lo extiende para que ocupe todo el ancho de la pantalla y prepara el espacio para la barra lateral donde irán los filtros. Enseguida, define dónde están guardados los datos, señalando una carpeta llamada Datos_Depurados y especificando los nombres de los tres archivos de datos socioeconómicos que se utilizarán.

El Corazón: La Carga y la Combinación de Datos

La parte más importante del programa es una sección llamada `load_data`, que funciona como una fábrica de datos. Esta función está marcada con una instrucción crucial: usar la memoria caché. Esto significa que la aplicación recordará el resultado de esta tarea (cargar y combinar los datos) para no tener que repetirla cada vez que el usuario interactúe con la página, logrando que el dashboard sea muy rápido.

Dentro de esta fábrica, el programa realiza dos tareas principales. La primera es unir las dos primeras hojas de datos (`FILE_UNO` y `FILE_DOS`). Estas dos hojas contienen información complementaria sobre los Bloques Censales (áreas geográficas pequeñas). El código abre la primera tabla para obtener datos como la población total y el ingreso. Luego, abre la segunda tabla, que tiene el desempleo y la pobreza. Para combinarlas en una sola tabla coherente, utiliza la columna `CensusTract` (Bloque Censal) como la clave de unión, asegurándose de que la información del desempleo y la pobreza se pegue exactamente al Bloque Censal correcto. Una vez unidas, las columnas técnicas se renombran a nombres más claros, como 'Ingreso Per Cápita' y 'Tasa de Desempleo', para que sean fáciles de entender en la aplicación.

La segunda tarea es cargar la tercera hoja de datos (`FILE_COUNTRY`), que ya contiene información resumida a nivel de Condado. También a esta tabla se le cambian los nombres de las columnas para mantener la consistencia con la tabla de Bloques Censales.

Finalmente, si todo sale bien, la fábrica guarda las dos tablas finales (la tabla de Bloques Censales y la tabla de Condados) y muestra un mensaje de éxito en la barra lateral. Si falta algún archivo o hay un error en la unión, el código está preparado para mostrar una advertencia clara al usuario.

Construcción del Tablero Interactivo

Con los datos ya cargados y combinados, el código procede a construir la interfaz visible.

Primero, le pone un título llamativo y verifica si la carga de datos fue exitosa.

Luego, se enfoca en la barra lateral izquierda, que es el centro de control del usuario. Aquí se crean dos menús desplegables:

1. Un Selector de Origen de Datos, donde el usuario puede elegir si quiere analizar la información detallada por Bloque Censal o el resumen por Condado.
2. Un Filtro por Estado, donde la aplicación toma la lista única de Estados presentes en la tabla elegida y permite al usuario seleccionar un Estado específico para concentrar el análisis.

La Presentación de Resultados



Una vez que el usuario selecciona un Estado, la aplicación entra en la etapa de visualización.

En primer lugar, filtra la tabla para mostrar solo los datos del Estado seleccionado. Luego, calcula las estadísticas de resumen: el promedio del Ingreso Per Cápita, la Tasa de Desempleo promedio y la Tasa de Pobreza promedio. Estos tres números cruciales se muestran en tarjetas de métricas dentro de la aplicación, distribuidos en tres columnas para una vista rápida y concisa de la situación del Estado.

Finalmente, el código genera el gráfico interactivo central, que es un gráfico de dispersión (puntos). Este gráfico cruza el Ingreso Per Cápita (en el eje horizontal) contra la Tasa de Desempleo (en el eje vertical) para cada Bloque Censal o Condado. Para hacerlo aún más informativo, el tamaño de cada punto representa la Población Total, y el color indica la Tasa de Pobreza. De esta manera, el usuario puede ver de un vistazo si las áreas con alto ingreso tienen bajo desempleo, o si la población es mayor en las áreas con alta pobreza. El gráfico se ajusta automáticamente para lucir bien y se presenta en la página, completando el dashboard.

Si el usuario no ha seleccionado nada o si el Estado seleccionado no tiene datos en la tabla, se muestra un mensaje amable pidiendo la selección o informando sobre la falta de datos. En esencia, este código transforma un conjunto disperso de hojas de cálculo en una herramienta de análisis geográfico centralizada, rápida y visualmente potente.

Algunos de los conjuntos en el dashboard son (no pongo todos por extensión):



Relación Ingreso Per Cápita vs. Tasa de Desempleo (por Condado)

Ingreso Per Cápita vs. Tasa de Desempleo en Indiana por Condado



Más otros más que sustentan la explicación del dato.

Explicación descriptiva de los datos

Este es un análisis narrado de los resultados estadísticos proporcionados, los cuales exploran diversos aspectos socioeconómicos y demográficos de los datos.

A. Análisis de Ingreso y Pobreza

A.1. Ingreso Promedio (Income) e Ingreso Per Cápita (IncomePerCap)

El análisis revela las áreas con los **mayores niveles de riqueza** según el ingreso promedio y el ingreso per cápita:

Clasificación	Estado/Condado	Ingreso Promedio	Ingreso Per Cápita
Top 5 por Estado	New Jersey, Connecticut, District of Columbia, Maryland, Massachusetts	\$73,014 (New Jersey)	\$47,675 (District of Columbia)

Top 5 por Condado	Loudoun (VA), Falls Church city (VA), Fairfax (VA), Howard (MD), Arlington (VA)	\$123,453 (Loudoun, VA)	\$65,600 (Falls Church city, VA)
--------------------------	---	-------------------------	----------------------------------

El **Condado de Loudoun, Virginia**, encabeza la lista con un ingreso promedio significativamente alto de \$123,453. Llama la atención que los **cinco condados con mayor ingreso** se concentran en el área de **Virginia y Maryland**, lo que sugiere una alta concentración de riqueza en la región de la capital nacional.

A.2. Distribución de Variables de Ingreso y Error

Variable	Media (Mean)	Mediana (50%)	Desviación Estándar (Std)	Rango (Max-Min)
Income	\$46,124	\$44,749	\$12,908	\$112,954
IncomePerCap	\$23,974	\$23,458	\$6,193	\$59,722

El **ingreso promedio** de los datos es de aproximadamente \$46,124, con una distribución relativamente simétrica (media y mediana cercanas). Los errores promedio, **IncomeErr** (\$2,848) e **IncomePerCapErr** (\$1,359), son bajos en comparación con los ingresos, indicando una **buena precisión** en las estimaciones reportadas.

A.3. Correlación y Diferencias de Ingreso

- **Correlación entre Ingreso y Pobreza:** Existe una **correlación negativa fuerte** (todos los valores $|r| > 0.7$) entre las variables de ingreso y las tasas de pobreza (Poverty y ChildPoverty). Esto confirma, como se espera, que **a mayor ingreso, menor es la tasa de pobreza** (y viceversa).
- **Prueba T de Ingreso Promedio:** Al comparar el ingreso promedio de un grupo de estados con alta representación en los datos (Texas, Georgia, Virginia, Kentucky, Missouri) contra otro grupo (Kansas, Illinois, North Carolina, Iowa, Tennessee), el **p-valor de 0.02863** (menor que 0.05) indica que hay una **diferencia estadísticamente significativa** en el ingreso promedio entre los dos grupos de estados.

B. Análisis Demográfico (Raza y Género)

B.1. Proporción de Grupos Étnicos

El resultado proporcionado para la proporción de grupos étnicos por Estado parece ser **inválido o incompleto**, ya que muestra una serie de ceros y etiquetas genéricas, por lo que no es posible realizar una interpretación significativa de esta sección.

B.2. Ratio de Género (Hombres/Mujeres)

Estado	Ratio de Género (Hombres/Mujeres)
Alaska	1.100
North Dakota	1.040
Wyoming	1.040

El **ratio de género (Hombres/Mujeres)** más alto se encuentra en **Alaska** (1.100), lo que significa que hay aproximadamente **110 hombres por cada 100 mujeres** en el estado. Le siguen North Dakota y Wyoming, también con una ligera predominancia de hombres.

B.3. Correlación entre Raza e Indicadores Socioeconómicos

- **Porcentaje 'Black' y 'Unemployment'**: Coeficiente de correlación **r=0.353**. Esta es una correlación **positiva débil a moderada**, sugiriendo que las áreas con un mayor porcentaje de población 'Black' tienden a tener tasas de desempleo ligeramente más altas.
- **Porcentaje 'Asian' e 'IncomePerCap'**: Coeficiente de correlación **r=0.399**. Esta es una correlación **positiva débil a moderada**, sugiriendo que las áreas con un mayor porcentaje de población 'Asian' tienden a tener un ingreso per cápita ligeramente mayor.

C. Análisis de Empleo y Desempleo

C.1. Tasa Promedio de Desempleo

Clasificación	Estado/Condado	Tasa Promedio de Desempleo

Top 5 por Estado	Puerto Rico, Mississippi, Arizona, South Carolina, Alabama	19.37% (Puerto Rico)
Top 5 por Condado	Adjuntas (PR), Lares (PR), Jayuya (PR), Orocovis (PR), Cataño (PR)	36.5% (Adjuntas, PR)

Puerto Rico muestra una tasa de desempleo promedio de casi el **doble** de la de los siguientes estados (Mississippi, 12.02%), y sus condados ocupan los primeros lugares, con el **Condado de Adjuntas** registrando la tasa más alta con un 36.5%. Esto indica un grave problema de desempleo en Puerto Rico en comparación con el resto de las áreas analizadas.

C.2. Promedio General de Tipo de Empleo y Sector Laboral

El panorama laboral promedio en los datos es el siguiente:

Tipo de Empleo	Proporción Promedio	Sector Laboral	Proporción Promedio
Professional	30.99%	PrivateWork	74.24%
Office	22.21%	PublicWork	17.54%
Service	18.34%	SelfEmployed	7.93%
Production	15.73%	FamilyWork	(No mostrado)
Construction	12.72%		

El sector **Profesional** es el tipo de empleo más prevalente, y el **empleo privado** es, con diferencia, el principal sector laboral (más del 74% del total).

C.3. Regresión Lineal: Unemployment ~ Poverty

El modelo de regresión lineal simple busca explicar la tasa de desempleo ('Unemployment') a partir de la tasa de pobreza ('Poverty'):

$$\text{Unemployment} = 1.9633 + 0.3506 \times \text{Poverty}$$

- **Ajuste del Modelo (R2):** El R2 es de 0.508, lo que indica que la **tasa de pobreza explica aproximadamente el 50.8% de la variación en la tasa de desempleo**. Se considera un ajuste de moderado a fuerte.
- **Significancia:** El coeficiente de 'Poverty' (0.3506) es **altamente significativo** ($p < 0.000$), lo que confirma una **relación positiva y fuerte**: por cada aumento de un punto porcentual en la tasa de pobreza, la tasa de desempleo aumenta en aproximadamente 0.35 puntos porcentuales.

C.4. Comparación de Ingresos (Income) - Kruskal-Wallis

El test de Kruskal-Wallis, usado para comparar medianas entre dos grupos, arrojó un **p-valor extremadamente bajo ($8.975e-104$)**. La conclusión es que existe una **diferencia estadísticamente significativa en la mediana de ingresos entre el grupo de empleo 'Professional' y el grupo 'Production'**. Esto sugiere que los profesionales perciben un ingreso significativamente diferente (probablemente mayor) que los trabajadores de producción.

D. Análisis de Desplazamiento y Transporte

D.1. Distribución de MeanCommute (minutos)

El **tiempo promedio de viaje al trabajo ('MeanCommute')** es de **23.28 minutos**. La mayoría de los viajes se encuentran entre **19.5 minutos (percentil 25)** y **26.8 minutos (percentil 75)**, con un máximo de 44.0 minutos, lo que indica que, en general, los tiempos de desplazamiento son manejables, con poca variabilidad (Std. Dev. ≈ 5.6 minutos).

D.2. Modos de Transporte Promedio por Estado (Top 5 en Transit)

Estado	Drive	Transit	Walk
District of Columbia	33.70%	37.40%	12.90%
New Jersey	75.47%	7.77%	2.81%
New York	74.21%	6.49%	4.87%

El **District of Columbia** se destaca notablemente. A diferencia de los otros estados donde el uso del automóvil ('Drive') supera el 70%, en **D.C. el uso del transporte público ('Transit') es el más alto (37.4%)**, superando incluso el uso del automóvil.

D.3. Correlación entre Transit e IncomePerCap

El coeficiente de correlación Pearson entre el uso de transporte público ('Transit') y el ingreso per cápita ('IncomePerCap') es **$r=0.313$** . Esta es una **correlación positiva débil a moderada**, lo que sugiere que las áreas con mayor dependencia del transporte público tienden a tener un ingreso per cápita ligeramente más alto.

Explicación gráfica de los estadísticos



La siguiente es una explicación de los resultados del análisis exploratorio de datos (EDA) enfocada en la **distribución visual de las variables de ingreso y del tiempo de viaje promedio**, basándose en los histogramas proporcionados.

Distribución de las Variables de Ingreso y Error

Los gráficos de distribución de **Income** (Ingreso), **IncomePerCap** (Ingreso Per Cápita), **IncomeErr** (Error de Ingreso) e **IncomePerCapErr** (Error de Ingreso Per Cápita) revelan información clave sobre la concentración y la dispersión de estas métricas económicas.

Ingreso Promedio (**Income**) e Ingreso Per Cápita (**IncomePerCap**)



- **Asimetría Positiva (Derecha):** Ambas distribuciones (**Income** e **IncomePerCap**) muestran una **asimetría hacia la derecha** (o sesgo positivo). La mayoría de los datos se concentran en los valores más bajos y moderados (alrededor de \$25,000 a \$50,000 para **Income** y \$15,000 a \$30,000 para **IncomePerCap**), mientras que una "cola" más larga se extiende hacia los valores más altos.
- **Interpretación:** Esto es típico en las métricas de ingreso, ya que la mayoría de la población se encuentra en el rango de ingresos medio o bajo, y solo una **pequeña proporción de áreas o condados registra ingresos extremadamente altos**.



Errores de Ingreso (IncomeErr e IncomePerCapErr)

- **Asimetría Fuerte y Concentración en Cero:** Las distribuciones de los errores (IncomeErr e IncomePerCapErr) están **fuertemente concentradas cerca de cero**.
- **Interpretación:** Esto es un indicio muy positivo para la calidad de los datos. La fuerte concentración en valores bajos significa que la **mayoría de las estimaciones de ingreso tienen un margen de error pequeño**, confirmando que las variables de


ingreso son generalmente precisas y confiables en la muestra de datos. Los pocos valores de error altos (la "cola") podrían corresponder a áreas con menor población o mayor variabilidad de ingresos, donde la precisión del censo es naturalmente menor.



Distribución del Tiempo Promedio de Viaje (MeanCommute)

El gráfico de la distribución de **MeanCommute** (Tiempo promedio de viaje en minutos) muestra una forma muy clara y característica:

- **Forma de Campana (Distribución Normal Aproximada):** La distribución se asemeja fuertemente a una **distribución normal o de campana de Gauss**, con la mayoría de los valores agrupados alrededor de la media.
- **Concentración Central:** El pico de la distribución se encuentra claramente entre los **20 y 25 minutos**, lo cual coincide con el valor promedio de 23.28 minutos reportado en el análisis estadístico (D.1).
- **Simetría:** La distribución es bastante **simétrica**, lo que significa que es igualmente probable encontrar tiempos de viaje ligeramente más cortos (por ejemplo, 15 minutos) que ligeramente más largos (por ejemplo, 30 minutos) que la media.
- **Interpretación:** Esta forma indica que, en general, los tiempos de viaje en las áreas censales analizadas están **bien controlados** y no están fuertemente sesgados hacia viajes extremadamente largos. La mayoría de los condados o áreas censales experimentan un tiempo de viaje que se desvía mínimamente de la media de 23 minutos.



Análisis Detallado

Este análisis exploratorio de datos (EDA) se basa en un conjunto de datos poblacionales y socioeconómicos, enfocado en el archivo `df_2015_depurado.csv` que contiene 3,218 registros de lo que parecen ser Census Tracts (o unidades similares) a nivel de Estado y Condado en Estados Unidos y Puerto Rico. El objetivo es describir las distribuciones, las

relaciones entre variables clave y las variaciones geográficas en el ingreso, la demografía, el empleo y el transporte.

1. Distribución y Análisis del Ingreso

El análisis se centró en las variables de ingreso: Income (ingreso promedio) e IncomePerCap (ingreso per cápita).

1.1. Distribución de las Variables de Ingreso y Error

Las distribuciones de las cuatro variables de ingreso y sus errores (Income, IncomePerCap, IncomeErr, IncomePerCapErr) muestran un patrón común (observado en la segunda imagen):

- Income e IncomePerCap exhiben una distribución sesgada positivamente (hacia la derecha). Esto es común en variables de ingreso, indicando que la mayoría de los registros se agrupan en valores inferiores a la media, con una "cola" de registros con ingresos muy altos. El Income promedio es de 46,123.62, con una desviación estándar considerable (12,908.43), y un rango desde 10,499.0 hasta 123,453.0. La mediana (\$44,748.5) es inferior al promedio, lo que confirma el sesgo a la derecha. El IncomePerCap sigue una tendencia similar, con un promedio de \$23,974.10.
- Las variables de error (IncomeErr e IncomePerCapErr) también muestran un fuerte sesgo a la derecha, con la mayoría de los valores agrupados cerca de cero y una larga cola de errores más grandes.

1.2. Variación Geográfica del Ingreso

Se observa una marcada disparidad en el ingreso promedio por región:

- Por Estado (Top 5): Los estados con mayor ingreso promedio son New Jersey (\$73,014.10), Connecticut (\$71,184.13), y el District of Columbia (\$70,848.00). Estos valores superan significativamente la media general del conjunto de datos.
- Por Condado (Top 5): Los condados con mayor ingreso muestran valores excepcionalmente altos, siendo Loudoun, Virginia (\$123,453.0) el líder, seguido de cerca por Falls Church city, Virginia (\$120,522.0). Esto resalta la existencia de clusters de alta riqueza, particularmente en el área metropolitana de Washington D.C. (Fairfax, Arlington, Howard).

1.3. Relación entre Ingreso y Pobreza

El análisis de correlación de Pearson reveló una correlación negativa y muy fuerte entre las variables de ingreso y las variables de pobreza.

Esta relación es intuitivamente esperada: a mayor ingreso, menor es la tasa de pobreza (y pobreza infantil) en el área.

1.4. Prueba de Hipótesis de Ingresos

Una prueba T comparando el Ingreso Promedio entre dos grupos de estados (Texas, Georgia, Virginia, Kentucky, Missouri vs. Kansas, Illinois, North Carolina, Iowa, Tennessee) concluyó que existe una diferencia significativa en el ingreso promedio entre los grupos ($p < 0.05$)

). Esto sugiere que la ubicación geográfica por estado es un factor importante en la determinación del ingreso.

2. Análisis Demográfico y Correlaciones

2.1. Ratio de Género

El Ratio de Género (Hombres/Mujeres) por estado muestra que Alaska tiene el ratio más alto (1.10), indicando una mayor proporción de hombres. Le siguen North Dakota (1.04) y Wyoming (1.04). Esto podría estar relacionado con factores económicos como industrias dominadas por hombres (ej. extracción de recursos) o patrones migratorios.

2.2. Correlaciones Demográficas Clave

Se exploró la relación de dos grupos minoritarios con variables socioeconómicas:

- Porcentaje Black (Negro) vs Unemployment (Desempleo): La correlación es positiva pero moderada ($r \approx 0.353$)
 -). Esto sugiere que los lugares con una mayor proporción de población negra tienden a tener mayores tasas de desempleo, aunque otros factores también influyen.
 - Porcentaje Asian (Asiático) vs IncomePerCap (Ingreso Per Cápita): La correlación es positiva pero moderada ($r \approx 0.399$)
 -). Esto indica que las áreas con mayor proporción de población asiática tienden a tener un ingreso per cápita más alto.
-

3. Empleo y Pobreza

3.1. Tasas de Desempleo

Las tasas de desempleo promedio varían dramáticamente por región:

- Por Estado (Top 5): Puerto Rico lidera con una tasa de desempleo promedio extremadamente alta (19.37%), seguido por Mississippi (12.02%) y Arizona (11.97%).
- Por Condado (Top 5): Los condados con las tasas más altas se encuentran todos en Puerto Rico, con Adjuntas alcanzando un 36.5% y Lares un 35.2%, destacando un problema estructural de desempleo en la isla.

3.2. Estructura Laboral

El tipo de empleo se distribuye de la siguiente manera:

- Tipo de Empleo (Promedio General): La categoría Professional es la más grande (30.99%), seguida por Office (22.21%) y Service (18.34%). Esto refleja una economía dominada por el sector servicios y profesionales.
- Sector Laboral (Promedio General): La mayoría trabaja en el PrivateWork (74.24%), con PublicWork (17.54%) y SelfEmployed (7.93%) en segundo y tercer lugar, respectivamente.

3.3. Modelado: Desempleo vs Pobreza

Se realizó una regresión lineal para modelar la relación entre Unemployment (Desempleo) y Poverty (Pobreza):

$$\text{Unemployment} = 1.9633 + 0.3506 \times \text{Poverty}$$

- Existe una relación positiva y estadísticamente significativa donde un aumento en la tasa de pobreza está fuertemente asociado con un aumento en la tasa de desempleo. El ajuste del modelo es de moderado a fuerte.

3.4. Diferencia de Ingreso por Tipo de Empleo

La prueba de Kruskal-Wallis comparando la mediana de ingresos entre el grupo 'Professional' y el grupo 'Production' reveló una diferencia significativa en la mediana de ingresos (

$p \approx 8.975 \times$

10

-104

). Esto confirma la esperada disparidad salarial entre las ocupaciones de alto nivel (Professional) y las de manufactura o producción.

4. Transporte y Commute

4.1. Distribución del Tiempo Promedio de Viaje (MeanCommute)

La primera imagen (Distribución de MeanCommute) muestra un histograma con una curva de densidad que se asemeja a una distribución normal o gaussiana .

- Características: La distribución está centrada alrededor de la media (23.28 minutos) y la mediana (23.00 minutos). La mayoría de los tiempos de viaje se encuentran entre 15 y 30 minutos.
- Estadísticas: El MeanCommute promedio es de 23.28 minutos, con una desviación estándar de 5.60 minutos. El tiempo mínimo de viaje es de 4.9 minutos y el máximo es de 44.0 minutos.

4.2. Modos de Transporte por Estado

El uso del transporte varía significativamente:

- Transit (Transporte Público): District of Columbia (D.C.) domina el uso de tránsito (37.40%), muy por delante de New Jersey (7.77%) y New York (6.49%). D.C.

también tiene el porcentaje más bajo de personas que conducen solas (Drive: 33.70%), destacando un patrón de movilidad altamente dependiente del transporte público y alternativo.

- Drive (Conducir solo): La mayoría de los estados analizados presentan una alta dependencia del automóvil privado, con porcentajes de Drive superiores al 70%.

4.3. Correlación entre Transporte Público e Ingreso

Se encontró una correlación débil a moderada y positiva entre Transit (uso de transporte público) e IncomePerCap ($r \approx 0.313$

). Esta correlación sugiere que los lugares con un mayor uso de transporte público tienden a tener un ingreso per cápita más alto, lo cual podría estar impulsado por la concentración de altos ingresos y servicios en áreas urbanas densas (como D.C., New York y New Jersey) donde el transporte público es una opción más viable y, a menudo, necesaria.

5. Estructura Demográfica y Ciudadanía

Las columnas TotalPop, Men, Women, Hispanic, White, Black, Native, Asian, Pacific, y Citizen son cruciales para entender la composición de la población en cada área censal.

5.1. Distribución de la Población

La variable TotalPop (Población Total) es fundamental. Aunque no se mostró su distribución, típicamente en datos censales, el número de habitantes por tract o condado puede ser sesgado a la derecha, con muchos tracts pequeños y un número menor de áreas muy pobladas.

5.2. Ciudadanía y Grupos Étnicos

La columna Citizen (Ciudadanos) permite calcular el porcentaje de población que no es ciudadana, una variable importante para políticas sociales y electorales.

El análisis de la proporción de grupos étnicos (Hispanic, White, Black, etc.) muestra una gran heterogeneidad. Por ejemplo, aunque el resultado de la Proporción de grupos étnicos por Estado no fue concluyente en la sección B.1 del EDA, se puede inferir:

- Diversidad Concentrada: Los condados o estados con bajos porcentajes de White y altos porcentajes de Hispanic o Black y Native (ej. ciertas áreas en el Suroeste o en el Sur) probablemente enfrentarán desafíos socioeconómicos distintos a aquellos con alta concentración de población Asian (que se correlaciona moderadamente con un mayor IncomePerCap,
- $r \approx 0.399$
-).

6. Profundización en el Mercado Laboral

El análisis previo estableció la estructura general y la relación entre Desempleo y Pobreza. Aquí profundizamos en la composición y la dinámica.

6.1. Tipos de Empleo vs. Ingreso: Un Vistazo Ampliado

El promedio general del tipo de empleo es: Professional (30.99%), Office (22.21%), Service (18.34%), Production (15.73%), y Construction (12.72%).

La prueba de Kruskal-Wallis ya demostró que existe una diferencia significativa en la mediana de ingresos entre el empleo Professional y Production ($p \approx 0$).

Sería valioso extender este análisis a las demás categorías (Service, Office, Construction) para confirmar una jerarquía salarial clara en función de la ocupación. Generalmente, los trabajos Professional y Office suelen asociarse con mayores ingresos que Service, Production y Construction.

6.2. Sectores Laborales y su Estabilidad

Los sectores laborales se distribuyen así: PrivateWork (74.24%), PublicWork (17.54%), SelfEmployed (7.93%).

- La alta dependencia en PrivateWork (trabajo privado) indica que la economía del conjunto de tracts analizados es predominantemente impulsada por el sector privado.
- El PublicWork (trabajo público) puede actuar como un factor de estabilidad en el empleo y, potencialmente, en el ingreso, especialmente en tiempos de recesión.
- El SelfEmployed (trabajo autónomo) y FamilyWork (trabajo familiar, con un promedio general muy bajo) a menudo se asocian con mayor volatilidad en el ingreso. Analizar la correlación entre SelfEmployed y IncomeErr o Unemployment podría revelar una relación positiva, sugiriendo mayor riesgo económico en áreas con alto autoempleo.

7. Análisis de Pobreza e Impacto Infantil

Las variables Poverty y ChildPoverty (Pobreza Infantil) ya se correlacionaron fuertemente con el ingreso.

7.1. Disparidad en la Pobreza Infantil

- Esto implica que la pobreza de los niños es extremadamente sensible a las variaciones en el ingreso del área censal.
- Una visualización comparativa de los estados o condados con mayor ChildPoverty (ej. los condados en Puerto Rico o Mississippi) frente a los de mayor Poverty ayudaría a identificar dónde los niños son desproporcionadamente afectados por la falta de recursos.

8. Patrones de Commute y Conexión Socioeconómica

El análisis de transporte se centró en la correlación de Transit e IncomePerCap ($r \approx 0.313$).

Sin embargo, la mayor parte de la población se desplaza en coche.

8.1. El Eje Principal: Drive y MeanCommute

- El 75-80% de los viajes en la mayoría de los estados (excepto D.C.) se realizan en Drive (conducir solo).
- La distribución del MeanCommute (23.28 minutos) es Normal .
- Impacto Económico del Tiempo de Viaje: Sería relevante correlacionar MeanCommute con IncomePerCap. En áreas metropolitanas, un commute más largo puede indicar mayor distancia entre la vivienda asequible y los centros de trabajo de altos ingresos, pero también puede ser un factor de estrés y menor productividad.
- Correlación a explorar: Una correlación negativa entre Walk y Drive es esperada, al igual que una correlación positiva entre WorkAtHome y Professional, ya que este último grupo tiene mayor flexibilidad para el trabajo remoto.

8.2. Carpool y Transporte Alternativo

Los modos de transporte alternativo como Carpool (promedio del 8-9% en estados principales) son el segundo método más común después de Drive en la mayoría de las áreas.

- El Carpool está a menudo correlacionado negativamente con IncomePerCap, ya que puede ser una estrategia de ahorro de costos en lugar de una elección de estilo de vida, a diferencia de Transit en ciudades grandes.
 - Las variables OtherTransp (Otros transportes) y WorkAtHome son minoritarias (con un promedio de WorkAtHome en torno al 4-5%), pero su crecimiento indica tendencias futuras en la movilidad laboral.
-

Conclusiones del Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) ha revelado una marcada heterogeneidad socioeconómica y geográfica a través de las 3,218 áreas censales examinadas, destacando disparidades significativas en ingresos, empleo, demografía y patrones de movilidad a lo largo de los Estados Unidos y Puerto Rico.

1. Patrones y Disparidades del Ingreso

El ingreso es la variable central del análisis y demuestra un claro sesgo positivo en su distribución (Income promedio: \$46,123.62), lo cual es característico de las economías capitalistas: la mayoría se concentra en ingresos medios o bajos, con una "cola" de áreas con riqueza excepcional.

1.1. Disparidad Geográfica Extrema y Clusters de Riqueza

La ubicación geográfica es un determinante crucial del ingreso.

- A nivel Estatal, la riqueza se concentra en la Costa Este, con New Jersey (\$73,014.10), Connecticut (\$71,184.13) y el District of Columbia (\$70,848.00) liderando significativamente la media general.

- A nivel Condado, la disparidad es más aguda, con clusters de alta riqueza en áreas metropolitanas específicas, como el corredor de Washington D.C. (Loudoun, Virginia, \$123,453.0). Estos condados representan centros de alta renta que distorsionan el promedio nacional.

1.2. Fuerte Vínculo Inverso con la Pobreza

Las variables de ingreso (Income e IncomePerCap) mantienen una correlación negativa y muy fuerte (alrededor de

$r \approx -0.76$

) con las tasas de Poverty y ChildPoverty. Este resultado confirma la hipótesis fundamental de que el ingreso promedio de un área es el predictor más robusto de su nivel de pobreza. La significancia de la prueba T refuerza esta conclusión, al confirmar que las diferencias de ingreso entre grupos de estados son estadísticamente reales, no aleatorias.

2. Estructura del Mercado Laboral y Crisis de Empleo

El mercado laboral analizado se caracteriza por una fuerte dependencia del sector privado (74.24% de PrivateWork) y una estructura de empleo dominada por las categorías de mayor cualificación.

2.1. Jerarquía Salarial Confirmada

La distribución ocupacional se inclina hacia el sector de servicios avanzados, con la categoría Professional (30.99%) como la más grande. La prueba de Kruskal-Wallis confirmó una disparidad salarial significativa entre las ocupaciones de alto nivel y las de producción ($p \approx 0$

), lo que sugiere una clara jerarquía salarial donde las ocupaciones Professional y, presumiblemente, Office gozan de medianas de ingresos sustancialmente mayores que Production, Service y Construction.

2.2. Concentración de Desempleo y Problemas Estructurales

Las tasas de desempleo promedio son muy variables, pero destacan problemas estructurales severos en algunas regiones.

- Puerto Rico es un caso atípico y extremo, liderando con una tasa de desempleo promedio de 19.37%, con condados como Adjuntas alcanzando un alarmante 36.5%. Esto indica un problema económico y laboral profundamente arraigado en la isla.
-

3. Demografía, Desigualdad y Grupos Étnicos

El análisis reveló correlaciones importantes entre la composición racial/étnica y los resultados socioeconómicos.

3.1. Correlaciones Demográficas y Desigualdad

- Población Negra y Desempleo: La correlación positiva y moderada $r \approx 0.353$ entre el porcentaje de población Black y Unemployment sugiere que los lugares con mayor proporción de población negra enfrentan sistemáticamente mayores desafíos de empleo.
- Población Asiática e Ingreso: La correlación positiva y moderada $r \approx 0.399$ entre el porcentaje de población Asian y el IncomePerCap sugiere que las áreas con mayor presencia asiática tienden a tener ingresos per cápita más altos, aunque es esencial notar que esta es una correlación a nivel de área censal, no una afirmación sobre la distribución de ingresos dentro del grupo.

3.2. Ratio de Género

El ratio de género más alto en Alaska (1.10), seguido de Dakota del Norte y Wyoming, apunta a patrones demográficos impulsados por industrias de extracción de recursos o trabajo pesado, que históricamente atraen a una mayor proporción de hombres.

4. Movilidad y Conexión Socioeconómica

Los patrones de viaje reflejan una alta dependencia del automóvil privado y revelan una compleja interacción entre el transporte y el estatus socioeconómico.

4.1. Dominio del Automóvil

La inmensa mayoría de las áreas censales muestran una dependencia del automóvil privado, con porcentajes de Drive (conducir solo) superiores al 70%. La distribución del tiempo promedio de viaje (MeanCommute) es Normal (media: 23.28 minutos), indicando que la mayoría de los residentes tienen tiempos de viaje manejables.

4.2. El Rol Atípico del Transporte Público

District of Columbia es un claro valor atípico, con un uso de Transit (Transporte Público) que domina la movilidad (37.40%), y una dependencia mínima del automóvil privado. Esta excepcionalidad se relaciona con la correlación débil a moderada y positiva ($r \approx 0.313$)

) entre Transit e IncomePerCap. Esto sugiere que el uso de transporte público está impulsado por la densidad urbana y la concentración de empleos de altos ingresos en núcleos metropolitanos (D.C., New York, New Jersey), donde el transporte público es la opción más eficiente.

5. La Sensibilidad de la Pobreza Infantil

La correlación entre Income y ChildPoverty $r \approx -0.758$ es ligeramente más fuerte que la correlación con la pobreza general. Esto implica que el bienestar de los niños es particularmente sensible a las condiciones económicas del área censal, y que las caídas en el ingreso afectan desproporcionadamente a los hogares con niños. El análisis posterior

debería centrarse en los estados y condados con mayor ChildPoverty para entender los factores subyacentes a esta vulnerabilidad.

Posibles Mejoras y Próximos Pasos Analíticos

Si bien el EDA ha sido exhaustivo, los siguientes pasos se centrarán en la profundización predictiva y la validación de causalidad para convertir las correlaciones observadas en insights accionables.

1. Modelado Predictivo y Clasificación

- Segmentación Jerárquica: Utilizar modelos de regresión multi-nivel (o jerárquicos) para modelar el Ingreso o la Pobreza, anidando los Census Tracts dentro de los Condados, y los Condados dentro de los Estados. Esto permitiría estimar cuánto de la varianza total se debe al Estado y cuánto a las diferencias dentro del Condado.
- Clasificación de Áreas: Aplicar algoritmos de clustering no supervisado (ej. K-Means) para segmentar las áreas censales en grupos homogéneos (ej. "Centros de Alta Riqueza y Empleo", "Zonas Rurales de Baja Renta/Producción", "Áreas Urbanas con Alta Dependencia del Tránsito"). Esto transformaría la descripción en una tipología útil para la política pública.
- Ingreso vs. Ocupación: Realizar una regresión múltiple utilizando Income como variable dependiente y todos los tipos de empleo (Professional, Service, Production, etc.) como variables predictoras para cuantificar el impacto relativo de cada sector en el ingreso promedio del área.

2. Integración de Factores Contextuales y Externos

- Análisis Espacial: Integrar datos geográficos (GIS) para visualizar la distribución de los residuales de los modelos de regresión. Esto ayudaría a identificar si los errores (áreas que el modelo subestima o sobreestima) se agrupan espacialmente, lo que indicaría que factores no incluidos (ej. acceso a servicios, zonificación, o historia económica local) son importantes.
- Variable Externa de Educación: Incorporar una variable clave, como el Nivel Educativo Promedio (ej. porcentaje con título universitario). Se espera que la educación sea un factor mediador clave que aumente las correlaciones entre el tipo de ocupación y el ingreso, además de explicar una parte de la varianza de la pobreza.

3. Profundización en los Valores Atípicos y Variables de Error

- Análisis Detallado de Puerto Rico (PR): Dado el extremo desempleo, realizar un sub-análisis solo para los datos de PR, buscando correlaciones locales que puedan explicar su singularidad (ej. mayor dependencia del sector público o mayor correlación con el autoempleo).
- Modelado de la Incertidumbre: Modelar explícitamente las variables de error de ingreso (IncomeErr e IncomePerCapErr) como la variable dependiente. Esto permitiría identificar si el tamaño del error o la incertidumbre del censo está

correlacionado con la pobreza o con el porcentaje de población no ciudadana, lo que podría revelar áreas de mayor dificultad en la recopilación de datos.

Trabajo hecho por Carlos Alejandro López Rodríguez, estudiante de máster en el campus de Caja Mágica en la escuela ThePower by Prometeo.